Семинар 7.

Прогнозирование. Фиктивные переменные. Тест Чоу.

1. Для модели парной регрессии $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$, $i = 1, ..., 10$, известно, что

$$\sum_{i=1}^{10} y_i = 8, \sum_{i=1}^{10} x_i = 40, \sum_{i=1}^{10} y_i^2 = 26, \sum_{i=1}^{10} x_i^2 = 200, \sum_{i=1}^{10} y_i x_i = 20.$$

   Для некоторого наблюдения дано $x_0 = 10$. Предполагая, что данное наблюдение удовлетворяет исходной модели,

   (a) вычислите наилучший линейный несмещенный прогноз величины y_0;

   (b) оцените стандартную ошибку прогноза.

2. Рассмотрим следующую регрессионную модель зависимости логарифмазаработной платы $\ln(W)$ от уровня образования Edu, опыта работы Exp, Exp^2 и уровня образования родителей $Fedu$ и $Medu$:

$$\widehat{\ln(W_i)} = \hat{\beta}_1 + \hat{\beta}_2 Edu_i + \hat{\beta}_3 Exp_i + \hat{\beta}_4 Exp_i^2 + \hat{\beta}_5 Fedu_i + \hat{\beta}_6 Medu_i.$$

   Модель регрессии была отдельно оценена по выборкам из 35 мужчин и 23 женщин, и были получены остаточные суммы квадратов $RSS_1 = 34.4$ и $RSS_2 = 23.4$, соответственно. Остаточная сумма квадратов в регрессии, оцененной по объединенной выборке, равна 70.3. Протестируйте на 5% уровне значимости гипотезу об отсутствии дискриминации в оплате труда между мужчинами и женщинами.

3. Всего имеется 100 наблюдений. Для первых 50 наблюдений

$$X'X = \begin{pmatrix} 50 & 300 \\ 300 & 2100 \end{pmatrix}, X'y = \begin{pmatrix} 300 & 2000 \end{pmatrix}', y'y = 2100.$$

   По последним 50 наблюдениям:

$$X'X = \begin{pmatrix} 50 & 300 \\ 300 & 2100 \end{pmatrix}, X'y = \begin{pmatrix} 300 & 2200 \end{pmatrix}', y'y = 2500.$$

   По первым 50 наблюдениям оценивается модель $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$, по последним 50 наблюдениям оценивается модель $y_i = \gamma_1 + \gamma_2 x_i + \varepsilon_i$. Предположеним, что во всех 100 наблюдениях ε_i независимы и нормальны $N(0; \sigma^2)$. На уровне значимости 5% проверьте гипотезу $H_0 : \beta = \gamma$.

4. На основе квартальных данных с 2003 по 2021 год было оценено следующее уравнение регрессии, описывающее зависимость цены на товар P от нескольких факторов:

$$\hat{P}_i = 3.5 + 0.4X_i + 1.1W_i,$$

$$ESS = 70.4, RSS = 40.5.$$

Когда в уравнение были добавлены фиктивные переменные, соответствующие первым трем кварталам года Q_1, Q_2, Q_3, оцениваемая модель приобрела вид

$$P_i = \beta_1 + \beta_2 X_i + \beta_3 W_i + \beta_4 Q_{1i} + \beta_5 Q_{2i} + \beta_6 Q_{3i} + \varepsilon_i.$$

При этом ESS выросла до 86.4. Сформулируйте и проверьте гипотезу о наличии сезонности (на уровне значимости 5%).

5. (Универсиада по эконометрике, МГУ, 2018 год, отборочный этап). В некоторой отрасли заработная плата работника следующим образом зависит от его опыта работы и пола:

$$\ln W_i = \beta_1 + \beta_2 X_i + \beta_3 X_i^2 + \beta_4 X_i D_i + \varepsilon_i,$$

где W_i — заработная плата i-го работника в рублях в месяц, X_i — стаж i-го работника в годах, D_i — бинарная переменная, равная единице для женщин и нулю для мужчин, ε_i — случайные ошибки. Предполагается, что все предпосылки классической линейной модели множественной регрессии выполнены. Оценка параметров модели при помощи МНК на основе данных о десяти тысячах наблюдений позволила получить следующие результаты:

$$\widehat{\ln W_i} = 10 + 60X_i - 3X_i^2 - 12X_i D_i.$$

Оценка ковариационной матрицы вектора оценок коэффициентов имеет вид:

$$\widehat{\mathrm{Var}}(\hat{\beta}) = \begin{pmatrix} 51 & -20 & 2 & 0 \\ -20 & 9 & -1 & 0 \\ 2 & -1 & 0.1 & 0 \\ 0 & 0 & 0 & 0.4 \end{pmatrix}.$$

(a) Опираясь на полученные оценки параметров, изобразите на одном рисунке графики логарифмов заработной платы типичного работника и типичной работницы в зависимости от их стажа. Интерпретируйте полученный результат.

(b) Аналитик Афанасий предполагает, что женщины в данной отрасли достигают максимума своей производительности при стаже, равном 10 годам.

Соответственно и их заработная плата максимальна именно в этот момент. Сформулируйте (в терминах коэффициентов модели) гипотезу, которая соответствует предположению Афанасия, и проверьте её при уровне значимости 5%.

(c) Аналитик Евгения утверждает, следующее: «Если обозначить X_M^* — стаж работы, при котором зарплата мужчины максимальна, а X_W^* — стаж, при котором зарплата женщины максимальна, то окажется, что $X_M^* = X_W^* + 1$. То есть женщины достигают пика своей зарплаты на год раньше мужчин». Сформулируйте (в терминах коэффициентов модели) гипотезу, которая соответствует утверждению Евгении, и проверьте её на уровне значимости 5%.