Семинар 9.

Мультиколлинеарность: диагностика и последствия.

1. Известно, что выборочная корреляция между переменными X и Z равна 0.9.

   (a) Найдите коэффициенты VIF для X и Z в регрессии $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \varepsilon_i$.

   (b) В каких пределах могут лежать коэффициенты VIF для X и Z в регрессии $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \beta_4 W_i + \varepsilon_i$?

   Решение:

   (a) Для модели $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \varepsilon_i$ коэффициент VIF (фактор инфляции дисперсии) для переменной X вычисляется как:

   $$\text{VIF}_X = \frac{1}{1 - R_X^2}$$

   где R_X^2 — коэффициент детерминации в регрессии X на Z (и константу). Аналогично для Z.

   Поскольку между X и Z только одна корреляция, $R_X^2 = (r_{XZ})^2 = 0.9^2 = 0.81$.

   Тогда:

   $$\text{VIF}_X = \frac{1}{1 - 0.81} = \frac{1}{0.19} \approx 5.263$$

   Аналогично, $\text{VIF}_Z = \text{VIF}_X \approx 5.263$.

   (b) Для модели $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \beta_4 W_i + \varepsilon_i$ коэффициент VIF_X вычисляется как:

   $$\text{VIF}_X = \frac{1}{1 - R_X^2}$$

   где R_X^2 — коэффициент детерминации в регрессии X на Z и W.

   Известно, что $r_{XZ} = 0.9$. Корреляция X с W неизвестна, но R_X^2 может меняться в зависимости от связи W с X и Z.

   - Минимальный VIF: Если W не коррелирует с X ($r_{XW} = 0$), то R_X^2 остаётся равным 0.81, и $\text{VIF}_{\min} \approx 5.263$.
   - Максимальный VIF: Если W сильно коррелирует с X (например, $r_{XW} \approx 1$), то R_X^2 может стремиться к 1. В пределе $R_X^2 \to 1$, тогда $\text{VIF} \to \infty$.

   Таким образом, пределы для VIF_X и VIF_Z:

   $$\text{VIF} \in [5.263,\ +\infty)$$

2. Покажите, что при наличии высокой корреляции между неконстантными регрессорами наблюдается высокая дисперсия оценок наклонных параметров.

   Решение:

   Прежде чем приступить непосредственно к решению задания, давайте сделаем дополнительное упражнение, цель которого — объяснить, что находится в обратной матрице кросс-произведений $(X^TX)^{-1}$.

   Обозначим нашу матрицу $(X^TX)^{-1}$ как V. Она симметрична, $V^T = V$. По определению, $X^TX \cdot V = I$. Разобьём произведение на две части по-другому: $X^T \cdot XV = I$.

   Заметим, что $X_* = XV$ — это матрица такого же размера, как X, $n \times k$. Что же собой представляют эти звездануные иксы, X_*?

   Во-первых, $X_* = XV$, поэтому новые X_* — это линейные комбинации исходных X с весами из матрицы $V = (X^TX)^{-1}$. Например, $x_{1*} = v_{11}x_1 + v_{21}x_2 + \cdots + v_{k1}x_k$.

   Во-вторых, $X_*^TX_* = (XV)^TXV = V^TX^TXV = V = (X^TX)^{-1}$. Матрица кросс-произведений новых переменных является обратной к матрице кросс-произведений исходных переменных.

   В частности, $v_{11} = x_{1*}^Tx_{1*}$, а $v_{12} = v_{21} = x_{1*}^Tx_{2*}$.

   В-третьих, $X^TX_* = I$, например, новая переменная x_{1*} перпендикулярна всем старым переменным, кроме x_1. Ортогональность позволяет взглянуть на первую звездануту переменную как на остаток в регрессии. Первая ничем не выделяется, просто индексов меньше будет:

   $$x_{1*} = v_{11}x_1 + v_{21}x_2 + \cdots + v_{k1}x_k.$$

   Изолируем x_1 слева, а всё остальное перенесём вправо:

   $$x_1 = -\frac{v_{21}}{v_{11}}x_2 - \frac{v_{31}}{v_{11}}x_3 - \cdots - \frac{v_{k1}}{v_{11}}x_k + \frac{1}{v_{11}}x_{1*}.$$

   Мы только что заметили, что переменная x_{1*} перпендикулярна $x_2, x_3, \ldots, x_k$, поэтому перед нами регрессия x_1 на все остальные переменные X_{-1}:

   $$x_1 = \hat\beta_{12}x_2 + \hat\beta_{13}x_3 + \cdots + \hat\beta_{1k}x_k + e_1,$$

   где $e_1 = x_{1*}/v_{11}$ — это остаток от регрессии x_1 на $x_2, \ldots, x_k$, а $\hat\beta_{12} = -v_{21}/v_{11} = -v_{12}/v_{11}$ — оценка коэффициента при переменной x_2 в этой регрессии.

   Отсюда мы сразу видим, что $V = (X^TX)^{-1}$ — это матрица-мать всех регрессий! Хочешь узнать коэффициент в регрессии x_1 на все остальные переменные перед x_7? В уме: $\hat\beta_{17} = -v_{17}/v_{11}$.

Найдём, чему равен RSS_1 в этой регрессии:

$$RSS_1 = e_1^T e_1 = x_{1*}^T x_{1*}/v_{11}^2 = v_{11}/v_{11}^2 = 1/v_{11}.$$

Бинго! Ура, $v_{11} = 1/RSS_1$. Заметим, что $x_{1*} = e_1 v_{11} = e_1/RSS_1$. Типичный недиагональный элемент равен $v_{12} = -\hat{\beta}_{12} v_{11} = -\hat{\beta}_{12}/RSS_1$. И, наконец, матрица-мать всех регрессий для $k = 3$:

$$V = (X^T X)^{-1} = \begin{pmatrix} 1/RSS_1 & -\hat{\beta}_{12}/RSS_1 & -\hat{\beta}_{13}/RSS_1 \\ -\hat{\beta}_{21}/RSS_2 & 1/RSS_2 & -\hat{\beta}_{23}/RSS_2 \\ -\hat{\beta}_{31}/RSS_3 & -\hat{\beta}_{32}/RSS_3 & 1/RSS_3 \end{pmatrix}.$$

Например, первая строка этой матрицы несёт всю информацию о регрессии x_1 на x_2 и x_3. Заметим, что в силу симметрии V выполнено $\hat{\beta}_{12}/RSS_1 = \hat{\beta}_{21}/RSS_2$, поэтому элементы $(1,2)$ и $(2,1)$ совпадают.

Важное уточнение. Всё сказанное выше верно для любой матрицы X полного ранга, в том числе для модели с константой. Однако в модели с константой нас обычно интересует блок ковариационной матрицы, отвечающий наклонным коэффициентам. Этот блок выражается через центрированную матрицу неконстантных регрессоров:

$$\mathrm{Var}(\hat{\beta}_{\text{накл}}) = \sigma^2 (X_c^T X_c)^{-1},$$

где X_c — матрица неконстантных регрессоров после вычитания средних. Столбец константы в X_c не включается: при центрировании он превращается в нулевой столбец, и формулы с TSS и R^2 к нему неприменимы.

Пример. Рассмотрим модель

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + \varepsilon_i,$$

где x_2, x_3 — неконстантные регрессоры. Обозначим $X = (\mathbf{1}, x_2, x_3)$ и $Z = (x_2, x_3)$. Тогда

$$\mathrm{Var}\begin{pmatrix} \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix} = \sigma^2 (Z_c' Z_c)^{-1},$$

где Z_c — матрица центрированных x_2, x_3. Для двух центрированных регрессоров

$$(Z_c' Z_c)^{-1} = \frac{1}{1-R^2} \begin{pmatrix} \frac{1}{TSS_2} & -\frac{R}{\sqrt{TSS_2\, TSS_3}} \\ -\frac{R}{\sqrt{TSS_2\, TSS_3}} & \frac{1}{TSS_3} \end{pmatrix},$$

где $R = r_{x_2x_3}$, а $TSS_j = \sum_i (x_{ji} - \bar{x}_j)^2$. Отсюда

$$\mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2}{TSS_2} \cdot \frac{1}{1-R^2} = \frac{\sigma^2}{TSS_2} \cdot VIF_2,$$

и аналогично для $\hat{\beta}_3$. При $|R| \to 1$ обе дисперсии и ковариация растут. Дисперсия свободного члена $\hat{\beta}_1$ равна $\sigma^2 v_{11}$, где v_{11} — левый верхний элемент полной $(X'X)^{-1}$; она не описывается через VIF и может расти лишь косвенно, если средние x_2, x_3 не нулевые.

Рассмотрим поэтому пару центрированных неконстантных регрессоров x_{1c}, x_{2c}. Для них R^2 одинаков в регрессии x_{1c} на x_{2c} и в обратной регрессии и равен $R^2 = \hat{\beta}_{12}\hat{\beta}_{21}$. Поэтому

$$v_{12} = v_{21} = -\frac{\hat{\beta}_{12}}{RSS_1} = -\frac{\hat{\beta}_{21}}{RSS_2} = -\frac{R}{\sqrt{RSS_1 RSS_2}},$$

и

$$V_c = (X_c^T X_c)^{-1} = \begin{pmatrix} 1/RSS_1 & -\hat{\beta}_{12}/RSS_1 \\ -\hat{\beta}_{21}/RSS_2 & 1/RSS_2 \end{pmatrix} = \begin{pmatrix} \frac{1}{RSS_1} & -\frac{R}{\sqrt{RSS_1 RSS_2}} \\ -\frac{R}{\sqrt{RSS_1 RSS_2}} & \frac{1}{RSS_2} \end{pmatrix} =$$

$$= \frac{1}{1-R^2} \begin{pmatrix} \frac{1}{TSS_1} & -\frac{R}{\sqrt{TSS_1 TSS_2}} \\ -\frac{R}{\sqrt{TSS_1 TSS_2}} & \frac{1}{TSS_2} \end{pmatrix}.$$

Здесь мы воспользовались тем, что для центрированных переменных $RSS_j = TSS_j(1-R^2)$.

Вспомним, что ковариационная матрица вектора оценок наклонных коэффициентов равна $\sigma^2 V_c$. Последнее представление матрицы V_c позволяет выделить в каждом элементе ковариационной матрицы множитель

$$\frac{1}{1-R^2} = VIF.$$

Очевидно теперь, что с ростом VIF растёт дисперсия и ковариация оценок наклонных коэффициентов исходной модели, что и требовалось доказать.

Замечание о константе. Если один из столбцов X пропорционален константе, то в модели с константой это приводит к совершенной мультиколлинеарности: $X^T X$ вырождена, $(X^T X)^{-1}$ не существует, а VIF для такого столбца равен бесконечности. Формулы с TSS и $1/(1-R^2)$ к столбцу константы не применяются, поскольку после центрирования он обнуляется и $TSS = 0$.