Семинар 9.

Мультиколлинеарность: диагностика и последствия.

1. Известно, что выборочная корреляция между переменными X и Z равна 0.9.

   (a) Найдите коэффициенты VIF для X и Z в регрессии $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \varepsilon_i$.

   (b) В каких пределах могут лежать коэффициенты VIF для X и Z в регрессии $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \beta_4 W_i + \varepsilon_i$?

   Решение:

   (a) Для модели $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \varepsilon_i$ коэффициент VIF (фактор инфляции дисперсии) для переменной X вычисляется как:

   $$\text{VIF}_X = \frac{1}{1 - R_X^2}$$

   где R_X^2 — коэффициент детерминации в регрессии X на Z (и константу). Аналогично для Z.

   В регрессии X на Z и константу справедливо $R_X^2 = (r_{XZ})^2 = 0.9^2 = 0.81$.

   Тогда:

   $$\text{VIF}_X = \frac{1}{1 - 0.81} = \frac{1}{0.19} \approx 5.263$$

   Аналогично, $\text{VIF}_Z = \text{VIF}_X \approx 5.263$.

   (b) Для модели $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \beta_4 W_i + \varepsilon_i$ коэффициент VIF_X вычисляется как:

   $$\text{VIF}_X = \frac{1}{1 - R_X^2}$$

   где R_X^2 — коэффициент детерминации в регрессии X на Z и W.

   Известно, что $r_{XZ} = 0.9$. Корреляция X с W неизвестна, но R_X^2 может меняться в зависимости от связи W с X и Z.

   - Минимальный VIF: Если W не коррелирует с X ($r_{XW} = 0$), то R_X^2 остаётся равным 0.81, и $\text{VIF}_{\min} \approx 5.263$.
   - Максимальный VIF: Если W сильно коррелирует с X (например, $r_{XW} \approx 1$), то R_X^2 может стремиться к 1. В пределе $R_X^2 \to 1$, тогда $\text{VIF} \to \infty$.

   Таким образом, пределы для VIF_X и VIF_Z:

   $$\text{VIF} \in [5.263,\ +\infty)$$

2. Покажите, что при наличии высокой корреляции между неконстантными регрессорами наблюдается высокая дисперсия оценок наклонных параметров.

   Решение:

   Прежде чем приступить непосредственно к решению задания, давайте сделаем дополнительное упражнение, цель которого — объяснить, что находится в обратной матрице кросс-произведений $(X^TX)^{-1}$.

   Обозначим нашу матрицу $(X^TX)^{-1}$ как V. Она симметрична, $V^T = V$. По определению, $X^TX \cdot V = I$. Разобьём произведение на две части по-другому: $X^T \cdot XV = I$.

   Заметим, что $X_* = XV$ — это матрица такого же размера, как X, $n \times k$. Что же собой представляют эти звездануные иксы, X_*?

   Во-первых, $X_* = XV$, поэтому новые X_* — это линейные комбинации исходных X с весами из матрицы $V = (X^TX)^{-1}$. Например, $x_{1*} = v_{11}x_1 + v_{21}x_2 + \cdots + v_{k1}x_k$.

   Во-вторых, $X_*^TX_* = (XV)^TXV = V^TX^TXV = V = (X^TX)^{-1}$. Матрица кросс-произведений новых переменных является обратной к матрице кросс-произведений исходных переменных.

   В частности, $v_{11} = x_{1*}^Tx_{1*}$, а $v_{12} = v_{21} = x_{1*}^Tx_{2*}$.

   В-третьих, $X^TX_* = I$, например, новая переменная x_{1*} перпендикулярна всем старым переменным, кроме x_1. Ортогональность позволяет взглянуть на первую звездануту переменную как на остаток в регрессии. Первая ничем не выделяется, просто индексов меньше будет:

   $$x_{1*} = v_{11}x_1 + v_{21}x_2 + \cdots + v_{k1}x_k.$$

   Изолируем x_1 слева, а всё остальное перенесём вправо:

   $$x_1 = -\frac{v_{21}}{v_{11}}x_2 - \frac{v_{31}}{v_{11}}x_3 - \cdots - \frac{v_{k1}}{v_{11}}x_k + \frac{1}{v_{11}}x_{1*}.$$

   Мы только что заметили, что переменная x_{1*} перпендикулярна $x_2, x_3, \ldots, x_k$, поэтому перед нами регрессия x_1 на все остальные переменные X_{-1}:

   $$x_1 = \hat\beta_{12}x_2 + \hat\beta_{13}x_3 + \cdots + \hat\beta_{1k}x_k + e_1,$$

   где $e_1 = x_{1*}/v_{11}$ — это остаток от регрессии x_1 на $x_2, \ldots, x_k$, а $\hat\beta_{12} = -v_{21}/v_{11} = -v_{12}/v_{11}$ — оценка коэффициента при переменной x_2 в этой регрессии.

   Отсюда мы сразу видим, что $V = (X^TX)^{-1}$ — это матрица-мать всех регрессий! Хочешь узнать коэффициент в регрессии x_1 на все остальные переменные перед x_7? В уме: $\hat\beta_{17} = -v_{17}/v_{11}$.

Найдём, чему равен RSS_1 в этой регрессии:

$$RSS_1 = e_1^T e_1 = x_{1*}^T x_{1*}/v_{11}^2 = v_{11}/v_{11}^2 = 1/v_{11}.$$

Бинго! Ура, $v_{11} = 1/RSS_1$. Заметим, что $x_{1*} = e_1 v_{11} = e_1/RSS_1$. Типичный недиагональный элемент равен $v_{12} = -\hat{\beta}_{12} v_{11} = -\hat{\beta}_{12}/RSS_1$. И, наконец, матрица-мать всех регрессий для $k = 3$:

$$V = (X^T X)^{-1} = \begin{pmatrix} 1/RSS_1 & -\hat{\beta}_{12}/RSS_1 & -\hat{\beta}_{13}/RSS_1 \\ -\hat{\beta}_{21}/RSS_2 & 1/RSS_2 & -\hat{\beta}_{23}/RSS_2 \\ -\hat{\beta}_{31}/RSS_3 & -\hat{\beta}_{32}/RSS_3 & 1/RSS_3 \end{pmatrix}.$$

Например, первая строка этой матрицы несёт всю информацию о регрессии x_1 на x_2 и x_3. Заметим, что в силу симметрии V выполнено $\hat{\beta}_{12}/RSS_1 = \hat{\beta}_{21}/RSS_2$, поэтому элементы $(1,2)$ и $(2,1)$ совпадают.

Пример. Рассмотрим модель

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + \varepsilon_i.$$

Обозначим $X = (\mathbf{1}, x_2, x_3)$, $Z = (x_2, x_3)$, через Z_c — матрицу центрированных x_2, x_3.

В модели с константой нас интересует блок ковариационной матрицы, отвечающий оценкам наклонных коэффициентов $\hat{\beta}_2$ и $\hat{\beta}_3$:

$$\mathrm{Var}(\hat{\beta}_{\text{накл}}) = \sigma^2 (Z_c' Z_c)^{-1},$$

где Z_c — центрированные неконстантные регрессоры.

В случае пары центрированных регрессоров x_{2c}, x_{3c} вспомним, что R^2 одинаков в регрессии x_{2c} на x_{3c} и в обратной и равен

$$R^2 = \hat{\beta}_{23}\hat{\beta}_{32} = r_{23}^2.$$

Поэтому

$$v_{23}^2 = v_{32}^2 = \frac{\hat{\beta}_{23}}{RSS_2^{(c)}} \frac{\hat{\beta}_{32}}{RSS_3^{(c)}} = \frac{R^2}{RSS_2^{(c)} RSS_3^{(c)}}.$$

Поскольку в матрице V элемент $v_{23} = -\dfrac{\hat{\beta}_{23}}{RSS_2^{(c)}}$, а $RSS_2^{(c)} > 0$, знак v_{23} противоположен знаку $\hat{\beta}_{23}$. Так как $\hat{\beta}_{23}$ имеет тот же знак, что и выборочная корреляция

r_{23} (она же R), получаем $v_{23} = -\operatorname{sign}(R) \cdot |v_{23}|$. Следовательно:

$$v_{23} = -\frac{R}{\sqrt{RSS_2^{(c)} RSS_3^{(c)}}}.$$

Финально имеем

$$(Z_c' Z_c)^{-1} = \begin{pmatrix} \frac{1}{RSS_2^{(c)}} & -\frac{R}{\sqrt{RSS_2^{(c)} RSS_3^{(c)}}} \\ -\frac{R}{\sqrt{RSS_2^{(c)} RSS_3^{(c)}}} & \frac{1}{RSS_3^{(c)}} \end{pmatrix} = \frac{1}{1-R^2} \begin{pmatrix} \frac{1}{TSS_2} & -\frac{R}{\sqrt{TSS_2 TSS_3}} \\ -\frac{R}{\sqrt{TSS_2 TSS_3}} & \frac{1}{TSS_3} \end{pmatrix}.$$

Итак, $VIF = 1/(1-R^2)$ — общий множитель блока наклонов $\sigma^2 (X_c' X_c)^{-1}$. С ростом VIF растут дисперсии и ковариации оценок наклонных коэффициентов, чтд.